

Prediksi Fluktuasi Harga Komoditas Pangan Menggunakan Analisis Deret Waktu: Datavidia 9.0

Fadhlan Nur Rachman
School of Computer Science
BINUS University
Bandung, Indonesia
fadhlan.rachman@binus.ac.id

Kettin
School of Computer Science
BINUS University
Bandung, Indonesia
kettin@binus.ac.id

Pasya Kemal Halim
School of Computer Science
BINUS University
Bandung, Indonesia
pasya.halim@binus.ac.id

Abstract—Fluktuasi harga komoditas bahan pangan menjadi tantangan utama dalam perekonomian Indonesia, memengaruhi industri, kebijakan, serta daya beli masyarakat. Penelitian ini menggunakan pendekatan *Long Short-Term Memory* (LSTM) untuk meningkatkan akurasi prediksi harga bahan pangan di 34 provinsi Indonesia. Dataset yang digunakan mencakup periode Januari 2022 hingga Desember 2024, dengan prediksi yang diperlukan untuk bulan Oktober 2024 ke depan. Dalam proses pelatihan, data diubah menggunakan *StandardScaler* untuk normalisasi sebelum dimasukkan ke dalam model. Hasil penelitian menunjukkan bahwa model LSTM mampu menangkap pola temporal dari harga bahan pangan secara efektif, dengan metrik evaluasi utama menggunakan *Mean Absolute Percentage Error* (MAPE). Studi ini memberikan kontribusi dalam pengembangan metode prediksi harga pangan yang lebih akurat dan dapat mendukung perumusan kebijakan serta strategi bisnis di sektor pangan. (Abstract)

Kata Kunci: Prediksi harga pangan, LSTM, deret waktu, MAPE, data science.

I. PENDAHULUAN

Harga bahan pangan adalah aspek krusial dalam ekonomi, di mana produsen, pedagang, dan konsumen sangat bergantung pada kestabilannya. Harga yang tidak konsisten dan tidak memiliki kepastian menjadi tantangan utama para konsumen, terutama bagi mereka yang memiliki keterbatasan ekonomi. Selain itu, bagi pedagang dan produsen, ketidakstabilan harga dapat berdampak pada keuntungan, pengelolaan stok, serta strategi pemasaran yang harus disesuaikan secara dinamis. Oleh karena itu, pemahaman yang lebih baik mengenai pola harga pangan menjadi sangat penting agar berbagai pihak dapat mengambil keputusan yang lebih tepat dalam menghadapi dinamika pasar.

Di masa lalu, metode konvensional telah digunakan untuk memperkirakan harga bahan pangan, tetapi seringkali tidak memberikan hasil yang akurat, sehingga peluang untuk memprediksi harga bahan pangan dengan tepat sangat kecil. Saat ini, *Machine Learning* (ML) membantu memprediksi harga komoditas bahan pangan, sehingga memungkinkan pemangku kepentingan untuk mengambil keputusan yang lebih baik terkait perdagangan dan kebijakan pangan. Namun, prediksi yang dihasilkan masih memiliki keterbatasan akurasi.

Artikel ilmiah ini berfokus pada beberapa penelitian yang telah dilakukan dalam bidang prediksi harga pangan serta memperkenalkan pendekatan baru menggunakan LSTM *Neural Network Model* untuk melakukan prediksi data berbasis *time series* yang kami rasa berguna dalam meningkatkan akurasi prediksi harga bahan pangan.

II. METODE ANALISIS

A. Dataset

Dataset yang digunakan dalam penelitian ini adalah dataset harga bahan pangan yang disediakan oleh Badan Pangan Nasional. Data mencakup harga dari berbagai jenis bahan pangan di 34 provinsi Indonesia selama satu periode Januari 2022 hingga 31 Desember 2024.

Dalam penelitian ini, hanya data harga bahan pangan yang digunakan, tanpa menggunakan data pendukung seperti *Google Trends*, mata uang, atau harga komoditas global.

B. Preprocessing

- Handling Missing Values:** Data yang memiliki nilai hilang diisi dengan nilai median supaya memiliki outlier yang sedikit sehingga distribusi data tetap stabil dan nantinya mudah untuk diproses dan dipelajari oleh model.
- Feature Selection:** Hanya kolom numerik yang dipilih untuk memastikan model hanya menangani data kuantitatif yang relevan.
- Data Transformation:** Data dikonversi ke tipe numerik dengan menangani nilai non-numerik dan menghapus data yang tidak valid.
- Scaling:** Data dinormalisasi menggunakan *StandardScaler*, yang mentransformasikan data dengan rumus:

$$X'_i = \frac{X_i - \mu}{\sigma} = \frac{X_i - X_{\text{mean}}}{X_{\text{std}}} \quad (1)$$

di mana normalisasi ini memastikan data memiliki rata-rata 0 dan standar deviasi 1, sehingga lebih stabil untuk tahap pemodelan selanjutnya.


- Sliding Window Technique:** Untuk menangkap pola jangka pendek dalam data deret waktu, digunakan pendekatan jendela bergulir dengan panjang jendela lima hari:

$$X_t = \{X_{t-4}, X_{t-3}, X_{t-2}, X_{t-1}, X_t\}, Y_{t+1} = X_{t+1} \quad (2)$$

di mana setiap jendela digunakan sebagai input untuk memprediksi harga pada hari berikutnya.

C. Model

Model LSTM yang digunakan memiliki arsitektur sebagai berikut:



- **Input Layer:** Lapisan ini menerima data dalam bentuk sekuensial dengan dimensi (*window_size*, 1). Data yang telah diproses melalui teknik sliding *window* akan menjadi input bagi model untuk belajar pola dari harga bahan pangan sebelumnya. Lapisan ini sangat penting karena menentukan bagaimana data akan masuk ke dalam jaringan LSTM untuk diproses lebih lanjut.
- **LSTM Layer 1:** Lapisan pertama ini memiliki 128 unit dengan *return_sequences=True*, yang berarti lapisan ini akan mengembalikan seluruh urutan output untuk digunakan oleh lapisan LSTM berikutnya. Lapisan ini berfungsi untuk menangkap pola temporal dalam data dan membantu model memahami hubungan antar waktu dalam harga bahan pangan.
- **Dropout Layer:** Sebanyak 30% dari *neuron* dihapus secara acak selama pelatihan untuk mencegah *overfitting*. Dropout adalah teknik regulasi yang membantu meningkatkan generalisasi model, terutama ketika berhadapan dengan dataset yang terbatas atau memiliki variabilitas tinggi.
- **LSTM Layer 2:** Lapisan ini memiliki 64 unit dengan *return_sequences=True*. Fungsi utama lapisan ini adalah menyaring informasi yang relevan dari lapisan sebelumnya dan mempertahankan konteks temporal yang penting dalam urutan data. Dengan jumlah unit yang lebih kecil dibandingkan lapisan pertama, model dapat mengurangi kompleksitas perhitungan.
- **Dropout Layer:** Sama seperti sebelumnya, dropout 30% diterapkan untuk meningkatkan kemampuan model dalam menangani *overfitting* dan memastikan bahwa model tidak terlalu bergantung pada pola tertentu dalam data pelatihan.
- **LSTM Layer 3:** Lapisan terakhir ini memiliki 32 unit dengan *return_sequences=False*. Tidak seperti lapisan sebelumnya, *return_sequences=False* berarti hanya output terakhir dari urutan yang akan dikembalikan. Hal ini dilakukan untuk mereduksi dimensi keluaran menjadi satu nilai yang nantinya akan digunakan dalam lapisan kepadatan (*Dense Layer*) berikutnya.
- **Dropout Layer:** Sekali lagi, dropout sebesar 30% diterapkan untuk memastikan bahwa model tetap mampu melakukan generalisasi dengan baik pada data uji dan data yang belum terlihat sebelumnya.
- **Dense Layer:** Lapisan ini memiliki 16 unit dengan fungsi aktivasi ReLU. Fungsi aktivasi ReLU

(*Rectified Linear Unit*) digunakan untuk memberikan non-linearitas pada model dan membantu dalam menangkap pola kompleks dalam data harga bahan pangan.

- **Output Layer:** Lapisan terakhir ini hanya memiliki satu unit dengan aktivasi linear. *Output* dari model ini merupakan prediksi harga bahan pangan untuk hari berikutnya berdasarkan pola yang telah dipelajari dari data historis.




Fig. 1. Arsitektur model LSTM univariate

Model ini dikompilasi menggunakan:

- **Optimizer:** *Adam Optimizer* yang digunakan dalam model ini adalah *Adam (Adaptive Moment Estimation)* dengan *learning rate* sebesar 0.003. *Adam* adalah algoritma optimasi yang menggabungkan keunggulan dari dua metode optimasi lainnya, yaitu Momentum dan RMSprop. *Optimizer* ini secara adaptif mengubah *learning rate* berdasarkan estimasi momentum gradien pertama dan kedua, sehingga dapat mempercepat konvergensi dan mengurangi kemungkinan jebakan pada minima lokal.
- **Evaluation Metrics:** MAPE untuk menilai performa prediksi. MAPE mengukur kesalahan rata-rata antara nilai aktual dan nilai prediksi dalam bentuk persentase. MAPE dipilih sebagai metrik evaluasi karena mudah diinterpretasikan dan memberikan gambaran kesalahan prediksi secara proporsional terhadap nilai aktual.

$$MAPE = \sum_{i=0}^n \left| \frac{y_i - \hat{y}_i}{\hat{y}_i} \right| \times 100\% \quad (3)$$

D. Training

Model dilatih menggunakan dataset yang telah diproses dengan konfigurasi berikut:

- **Jumlah Epoch** yang digunakan untuk pelatihan model adalah 100. Jumlah ini digunakan untuk memastikan bahwa jaringan LSTM memiliki cukup waktu untuk mempelajari pola dari data deret waktu. *Epoch* merujuk pada jumlah iterasi penuh di mana model melihat seluruh dataset training. Dengan jumlah *epoch* yang cukup besar, model memiliki kesempatan untuk melakukan pembelajaran yang lebih mendalam, tetapi juga harus diimbangi dengan strategi regulasi seperti *early stopping* untuk mencegah *overfitting*.
- **Batch Size** yang digunakan adalah 32. *Batch size* menentukan jumlah sampel yang diproses sebelum model memperbarui bobotnya dalam satu iterasi. Dengan *batch size* sebesar 32, model memproses 32 sampel sekaligus sebelum melakukan *backpropagation* dan pembaruan bobot. Pemilihan *batch size* ini merupakan kompromi antara efisiensi komputasi dan stabilitas pelatihan, di mana *batch size* yang terlalu kecil dapat menyebabkan pelatihan tidak stabil, sementara *batch size* yang terlalu besar dapat menyebabkan model kehilangan kemampuan generalisasi.
- **Validation Split, 30% dari data training digunakan untuk validasi.** Validasi berfungsi untuk mengevaluasi performa model pada data yang tidak dilatih. Proses ini bertujuan untuk memonitor generalisasi model dan mencegah *overfitting*. Dengan adanya *validation split*, model dapat dinilai secara objektif sebelum digunakan pada data uji yang sesungguhnya.
- **Early Stopping** digunakan sebagai teknik regulasi untuk mencegah *overfitting*. Jika validasi *loss* tidak membaik selama 10 *epoch* berturut-turut, pelatihan akan dihentikan lebih awal. Dengan cara ini, model tidak akan terus belajar dari data *training* ketika sudah mencapai titik optimal, sehingga dapat menghemat waktu komputasi dan menghindari degradasi kinerja akibat *overfitting*.
- **ReduceLROnPlateau** merupakan mekanisme adaptif yang menurunkan *learning rate* secara otomatis jika model mengalami stagnasi dalam peningkatan akurasi. Jika validasi *loss* tidak membaik setelah beberapa *epoch*, *learning rate* akan dikurangi dengan faktor tertentu. Hal ini memungkinkan model untuk terus belajar secara lebih halus dan mencegah terjebak di lokal minima.
- **Model Checkpointing** digunakan untuk menyimpan bobot terbaik selama proses pelatihan berdasarkan nilai validasi *loss*. Dengan teknik ini, meskipun model mengalami *overfitting* atau penurunan performa setelah beberapa *epoch*, bobot terbaik tetap dapat digunakan untuk melakukan prediksi. Hal ini sangat membantu dalam memastikan model yang digunakan adalah versi paling optimal dari seluruh proses pelatihan.

E. Testing

Setelah proses training selesai, model diuji menggunakan data test untuk mengevaluasi performanya. Evaluasi model dilakukan berdasarkan nilai **MAPE**, yang mengukur seberapa besar deviasi prediksi terhadap nilai aktual secara proporsional.

III. HASIL DAN PEMBAHASAN

A. Kinerja Model

Model LSTM yang dikembangkan menunjukkan performa yang cukup baik dalam memprediksi harga bahan pangan. Nilai **MAPE** yang dihasilkan berada dalam kisaran yang dapat diterima untuk peramalan harga komoditas, menunjukkan bahwa model mampu menangkap pola pergerakan harga dengan cukup akurat. Namun, performa model bervariasi tergantung pada jenis bahan pangan yang diprediksi. Beberapa bahan pangan dengan tren harga yang lebih stabil menunjukkan *error* yang lebih kecil dibandingkan dengan bahan pangan yang memiliki volatilitas tinggi.




Fig 2. Actual dan predicted data pada Tepung Terigu Curah

Visualisasi hasil prediksi dibandingkan dengan data aktual menunjukkan bahwa model mampu mengikuti tren harga dengan cukup baik. Namun, terdapat beberapa kasus di mana model mengalami kesulitan dalam memprediksi lonjakan harga yang tiba-tiba. Hal ini dapat disebabkan oleh faktor eksternal yang tidak dimasukkan ke dalam model, seperti kebijakan pemerintah, faktor cuaca, atau gangguan dalam rantai pasokan.

B. Analisis Kesalahan

Analisis kesalahan dilakukan dengan membandingkan prediksi model terhadap data aktual menggunakan **MAPE**. Dari hasil evaluasi, ditemukan bahwa model cenderung memiliki *error* yang lebih tinggi pada periode di mana terjadi perubahan harga yang ekstrem. Ini menunjukkan bahwa model LSTM masih memiliki keterbatasan dalam menangkap peristiwa tak terduga yang mempengaruhi harga bahan pangan secara drastis.

TABLE I. TABEL METRIK EVALUASI

Komoditas	MAPE
Bawang Merah	47%
Bawang Putih Bonggol	18%

Komoditas	MAPE
Beras Medium	13%
Beras Premium	12.6%
Cabai Merah Keriting	32%
Cabai Rawit Merah	11%
Daging Ayam Ras	9,8%
Daging Sapi Murni	19%
Gula Konsumsi	11%
Mnyak Goreng Curah	40%
Minyak Goreng Kemasan Sederhana	56%
Telur Ayam Ras	79%
Tepung Terigu (Curah)	31%

Fig 3. Tabel Metrik Evaluasi Setiap Komoditas

Untuk melihat distribusi error, dilakukan analisis residual dengan melihat selisih antara harga aktual dan harga prediksi. Hasilnya menunjukkan bahwa sebagian besar error terkonsentrasi dalam kisaran yang rendah, tetapi terdapat beberapa outlier yang menunjukkan bahwa model terkadang gagal menangkap perubahan harga yang sangat cepat.




Fig 2. Histogram Distribusi Error Prediksi Model

Prediction Errors yang dimiliki oleh model mengikuti distribusi yang mendekati normal, dengan sebagian besar kesalahan berpusat di sekitar nol, yang mengindikasikan kinerja yang baik secara keseluruhan. Namun, ada beberapa kesalahan besar (*outlier*), dan *skewness* yang sedikit condong ke kanan menunjukkan bahwa model ini cenderung meremehkan harga lebih sering daripada melebih-lebihkannya.

C. Implikasi dan Manfaat

Hasil prediksi yang dihasilkan oleh model ini dapat memberikan manfaat bagi berbagai pihak, termasuk pelaku industri pangan, pedagang, serta pembuat kebijakan. Dengan adanya prediksi harga yang lebih akurat, pelaku usaha dapat merencanakan strategi pembelian dan penyimpanan stok bahan pangan dengan lebih efisien. Selain itu, pemerintah dapat menggunakan hasil peramalan ini untuk mengantisipasi lonjakan harga dan merancang kebijakan stabilisasi harga yang lebih efektif.




Fig 4. Grafik tren harga bahan pangan sebagai dasar pengambilan keputusan

Selain itu, model ini dapat digunakan sebagai dasar untuk pengembangan sistem prediksi harga pangan yang lebih komprehensif. Dengan menambahkan faktor eksternal seperti kondisi cuaca, nilai tukar mata uang, atau volume perdagangan, diharapkan model dapat memberikan prediksi yang lebih akurat di masa mendatang.

IV. KESIMPULAN

Penelitian ini berhasil mengimplementasikan model Long Short-Term Memory (LSTM) untuk memprediksi fluktuasi harga bahan pangan di 34 provinsi Indonesia menggunakan data dari Januari 2022 hingga Desember 2024. Dengan menerapkan teknik preprocessing seperti normalisasi menggunakan StandardScaler, sliding window, dan dropout untuk mencegah overfitting, model mampu menangkap pola temporal dalam data harga pangan. Evaluasi model menggunakan Mean Absolute Percentage Error (MAPE) menunjukkan bahwa performa prediksi bervariasi tergantung pada jenis bahan pangan, dengan beberapa komoditas menunjukkan error lebih tinggi akibat volatilitas harga yang ekstrem. Secara keseluruhan, model menunjukkan akurasi yang cukup baik dengan MAPE rata-rata sebesar 0.14930, yang dapat digunakan untuk mendukung perencanaan stabilisasi harga pangan.

REFERENCES

- [1] Bina Nusantara IT Division. (2021). LSTM (Long Short-Term Memory). Retrieved from <https://medium.com/bina-nusantara-it-division/lstm-long-short-term-memory-d29779e2ebf8>
- [2] Brownlee, J. (2017). Long Short-Term Memory Networks with Python: Develop Sequence Prediction Models with Deep Learning. Machine Learning Mastery.
- [3] Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- [4] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. Neural Computation, 9(8), 1735-1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- [5] Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. International Conference on Learning Representations (ICLR). <https://arxiv.org/abs/1412.6980>
- [6] McKinsey & Company. (2020). The future of supply chain: Data-driven decision making in commodity markets. Retrieved from <https://www.mckinsey.com/>
- [7] Olah, C. (2015). Understanding LSTMs. Retrieved from <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>
- [8] Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. Nature, 323(6088), 533-536. <https://doi.org/10.1038/323533a0>